VISÃO COMPUTACIONAL · GUIA DO APRESENTADOR & DEFESA TÉCNICA

DuoLibras — Roteiro de Apresentação e Q&A

Cola completa para os 11 slides com falas objetivas, números exatos e respostas às prováveis perguntas da banca.

Apresentador: Daniel Maffezzoli | **Duração estimada:** 9 a 11 minutos | **Slides:** 11 páginas | **App:** sinala-web.vercel.app

Cola Rápida dos Números-Chave	Módulo 1 (Letras A–Z)	Módulo 2 (Saudações)	Estudo de Caso (MINDS-Libras)
Papel no Projeto	Em produção no navegador	Em produção no navegador	Benchmark externo (fora do app)
Arquitetura	MLP (225 → 256 → 128 → 26)	GRU (128D × 32 frames, H=64)	GRU (128D × 32 frames, H=128)
Dataset	LibraSign: 26.000 (80/20 → 65.600 aug / 5.200 val)	32 base → 1.312 treino (40× aug) · 9 classes	588 de 1.200 vídeos (6 de 12 pessoas) · 20 sinais
Validação / Regra	Confiança ≥ 0,40 · Espera 1,2 s · 0,05 ms	Confiança ≥ 0,35 · Espera 1,2 s · 1,4 ms	Split por pessoa: 303 treino / 100 val / 185 teste
Métrica Principal	100% val. interna · V/U: 0% → 100%	100% em 1.600 var. · 11,11% sem Art. 3	15,68% → 27,03% → 51,89% (acaso = 5%)

Parte 1 · Roteiro Slide a Slide

Slide 1 · Capa — DuoLibras ~30 s

Objetivo: Apresentar o problema central e a proposta Edge-AI com privacidade.

"Bom dia. Eu vou apresentar o **DuoLibras**, uma plataforma educacional gamificada para o ensino de Libras em tempo real usando apenas uma webcam comum. O ponto central do projeto é que plataformas digitais atuais são passivas — mostram vídeos ou figuras, mas não avaliam se o aluno fez o sinal certo. Aqui, toda a visão computacional e a inferência neural rodam **100% no navegador do usuário** (Edge-AI via WebAssembly e ONNX), sem precisar de luvas, Kinect ou enviar nenhum vídeo para servidor."

Slide 2 · Pipeline em quatro etapas ~45 s

Objetivo: Dar a visão macro antes de entrar nas redes neurais.

"O sistema funciona em quatro etapas encadeadas a 30 FPS em vídeo 640×480. Primeiro, o **MediaPipe** extrai 21 pontos 3D da mão do aluno — como vocês veem na captura real do app à esquerda — e até 42 pontos no módulo bimanual. Segundo, transformamos essas coordenadas em um **descritor geométrico invariante** a rotação, posição e distância da câmera. Terceiro, dois modelos especialistas classificam: uma **MLP** para letras estáticas de A a Z e uma **GRU** para saudações em movimento. Quarto, só validamos o acerto após uma espera contínua de 1,2 segundo, evitando aprovar gestos acidentais de transição."

Slide 3 · Modelo 1: MLP para o alfabeto manual

~1 min

Objetivo: Explicar por que o descritor 225D resolve câmera e ângulo de pulso.

"No Módulo 1, em vez de passar coordenadas brutas (x, y, z) que quebram quando o aluno inclina o pulso ou chega mais perto da webcam, construímos um vetor analítico de **225 valores** puramente geométrico: são **210 distâncias euclidianas** entre todos os pares dos 21 pontos da mão, normalizadas pelo comprimento da palma, somadas a **15 ângulos de flexão** das articulações dos dedos. Esse vetor é invariante a rotação, translação e escala, e entra numa MLP simples com camadas de 256 e 128 neurônios com BatchNorm, ReLU e Dropout de 0,25, gerando 26 saídas. Na saída, um **verificador biomecânico** desempata pares mínimos críticos como U, V e R."

💡 **Conta de cabeça caso perguntem:** Combinação de 21 pontos 2 a 2 = (21 × 20) / 2 = 210 distâncias; 5 dedos × 3 articulações = 15 ângulos. Total = 225.

Slide 4 · Modelo 2: GRU para saudações dinâmicas

~50 s

Objetivo: Explicar a entrada bilateral 128D e diferenciar H=64 (app) de H=128 (MINDS).

"Para sinais que têm movimento — como Oi, Obrigado e Por favor — uma foto parada não basta. Usamos uma rede recorrente **GRU** sobre uma janela deslizante de **32 quadros**. Em cada quadro, montamos um vetor bilateral de **128 dimensões**: 63 coordenadas da mão esquerda mais 1 bit de máscara de presença, e 63 da direita mais 1 bit de máscara, tudo centrado no pulso e normalizado pelo raio da mão. As portas de atualização e reinício da GRU carregam o estado oculto ao longo dos 32 quadros. Vale destacar uma diferença importante de engenharia: o modelo de 9 classes exportado para o navegador usa **64 unidades ocultas** para máxima leveza, enquanto no estudo de caso de 20 classes da MINDS usamos 128."

Slide 5 · Treino de cumprimentos: os dados

~55 s

Objetivo: Mostrar transparência no tamanho da base real (32 → 1.312) e explicar o aumento.

"Aqui estão os números exatos do treino de saudações. Partimos de **32 sequências-base** para as 9 classes: 27 gravações de estúdio do V-Librasil (com 3 articuladores humanos) somadas a 5 vídeos externos do Acessibilidade Brasil e Spread the Sign — variando de 3 a 5 vídeos originais por sinal. Como 32 vídeos é uma base pequena, aplicamos um aumento espaço-temporal de **40 cópias por vídeo**, chegando a **1.312 sequências de treino** (entre 123 e 205 por classe). Em cada cópia sintética, aplicamos escala aleatória de 0,85 a 1,15, ruído gaussiano de desvio 0,015 apenas nas mãos visíveis — preservando as máscaras zeradas quando a mão está ausente — e reamostragem temporal elástica de 0,85 a 1,15 para simular pessoas sinalizando mais devagar ou mais rápido."

Slide 6 · Estudo de caso: MINDS-Libras

~1 min 10 s

Objetivo: Deixar cristalino que MINDS é um benchmark externo, NÃO está no app, e mostrar o efeito do split por pessoa.

"É fundamental separar o que está no app do que foi nosso estudo científico externo. O **MINDS-Libras não faz parte do currículo do DuoLibras** — ele é um benchmark de 20 sinais lexicais isolados usado para responder a uma pergunta crítica: uma GRU consegue generalizar para uma pessoa que nunca apareceu no treino? Do corpus total de 1.200 vídeos e 12 pessoas, processamos um recorte estrito com **6 sinalizadores (588 gravações)**, sem misturar ninguém entre as partições: 303 gravações de 3 pessoas no treino, 100 de 1 pessoa na validação e **185 sequências inéditas** de 2 pessoas no teste cego. Sem regularização, o modelo acerta só **15,68%**. Com aumento espaço-temporal e dropout, sobe para **27,03%**. Com a arquitetura regularizada e diversidade de sinalizadores, mais que triplica para **51,89%** — mais de 10 vezes acima do acaso, que em 20 classes seria 5%."

Slide 7 · Linha do tempo do desenvolvimento: letras (MLP)

~55 s

Objetivo: Mostrar a descoberta de engenharia (V vs U) e a honestidade metodológica.

"Voltando ao módulo de letras, esse slide mostra um problema clássico de Visão Computacional que descobrimos na prática: mesmo com 100% na validação do LibraSign, o modelo falhava em **0% ao trocar o punho entre V e U**. O motivo era correlação espúria: das 210 distâncias, 194 descreviam os dedos fechados do fundo do punho de um único sinalizante, e não os dois dedos ativos. Resolvemos em duas frentes: primeiro, gerando **65.600 amostras aumentadas** com transplante de punho entre doadores e jitter nas falanges dobradas; segundo, adicionando o **verificador biomecânico** que mede a extensão e o ângulo entre indicador e médio, elevando o teste de estresse para 100%. E sendo transparente: o artigo não avaliou letras em sinalizador externo novo; a evidência inter-sinalizador está nas saudações e no MINDS."

Slide 8 · Pipeline completo: da câmera à validação

~35 s

Objetivo: Consolidar as duas vias em paralelo com seus tempos reais.

"Resumindo a arquitetura inteira em um fluxo: a webcam entrega em 2,1 ms e o MediaPipe extrai os pontos em 27,5 ms. A partir daí o sistema bifurca conforme a lição: no Módulo 1 (1 mão), o descritor 225D leva 0,3 ms e a MLP roda em 0,05 ms, exigindo confiança ≥ 0,40 por 1,2 s. No Módulo 2 (até 2 mãos), o vetor 128D alimenta a janela de 32 quadros da GRU em 1,4 ms, com limiar ≥ 0,35 por 1,2 s. Somando 0,15 ms da renderização 3D, fechamos o quadro completo em **31,5 ms**, sustentando **31,7 FPS** no navegador."

Slide 9 · E os 100%? São validação interna

~1 min

Objetivo: Antecipar a crítica da banca mostrando maturidade científica sobre os 100%.

"Esse talvez seja o slide mais importante para a leitura crítica dos resultados. Tanto as letras quanto as saudações marcaram **100%**, mas nós deixamos explícito o que esse 100% realmente mede e o que ele **não prova**. Nas letras, 100% em 5.200 amostras da mesma base mostra que a rede aprendeu a geometria do LibraSign, mas não garante câmera ou mão inédita. No V vs U, 100% prova sucesso apenas no teste dirigido de transplante. E nas saudações, 100% nas 1.600 variantes sintéticas prova robustez a ruído e velocidade dentro dos 3 articuladores conhecidos — porque quando fizemos a ablação retendo o **Articulador 3** fora do treino, a acurácia despencou para **11,11%** (o acaso de 9 classes). Ou seja: os 100% comprovam convergência na base; a generalização real exige diversidade de pessoas."

Slide 10 · O app em uso: sinal da letra A

~40 s

Objetivo: Mostrar a experiência pedagógica (mão 3D + feedback imediato).

"Na prática, o aluno interage com essa interface: além da webcam com os 21 pontos em azul em tempo real e o selo de reconhecimento da letra A quando a MLP passa de 0,40, o DuoLibras resolve o problema de oclusão das figuras 2D com uma **mão humanoide 3D de 25 ossos** em Three.js que gira 360 graus, anima letras dinâmicas como J, Z, H, K e X, e permite trocar o tom de pele ou cores de destaque."

⚠️ **Nota visual rápida:** A imagem deste slide mostra apenas a webcam; comente oralmente apontando para os 5 pontos que na tela do navegador a mão 3D fica ao lado esquerdo desse feed de câmera (ou, se der tempo, troque o print pela tela completa do app).

Slide 11 · Validação por espera e execução local

~45 s

Objetivo: Fechar destacando o gargalo real (MediaPipe 87,3%) e o mecanismo anti-falso-positivo.

"Para encerrar, dois pontos finais de engenharia. À esquerda, o gráfico mostra a **histerese de espera de 1,2 segundo**: um gesto rápido de passagem interrompido em 0,5 s é descartado; o aluno só ganha os +10 XP quando sustenta o sinal corretamente sem interrupção. À direita, a decomposição de latência em Apple M4 revela o verdadeiro gargalo do pipeline: nossos modelos e matemática juntos (GRU 1,4 ms + Descritor 0,3 ms + MLP 0,05 ms) consomem menos de **6%** do tempo; **87,3% da latência (27,5 ms) está no detector MediaPipe**. Ainda assim, o conjunto fecha em 31,5 ms (31,7 FPS) 100% local, sem GPU e com privacidade total. Obrigado, estou aberto a perguntas."

Parte 2 · Respostas Rápidas para Possíveis Perguntas Técnicas (Q&A)

1. Por que usar MediaPipe + MLP/GRU em vez de treinar uma CNN 2D/3D direto nos pixels do vídeo?

Resposta: Três motivos: (1) **Custo e Edge-AI:** 3D CNNs densas exigem GPU dedicada e não rodam a 30 FPS em navegador de laptop comum, enquanto nossa MLP + GRU consomem juntos apenas 1,45 ms em CPU/WASM; (2) **Filtro semântico de fundo:** como mostra Feliciano et al. (2023), extrair o esqueleto 3D desacopla a mão de cor de parede, roupa e iluminação; (3) **Privacidade:** nenhum frame de vídeo sai da máquina do aluno.

2. Como vocês garantem matematicamente que o descritor 225D é invariante a rotação, translação e escala (SE(3))?

Resposta: Porque nenhuma coordenada absoluta (x, y, z) entra na rede. As 210 distâncias euclidianas par-a-par dependem apenas da distância relativa entre pontos (invariante a translação e rotação 3D rígida) e são divididas pela distância anatômica pulso–base do dedo médio (`||p0 − p9||`), o que cancela a escala/distância da câmera. Os 15 ângulos internos entre falanges são calculados por produto escalar normalizado (`arccos`), também invariante a posição, rotação e tamanho da mão.

3. Por que trocar o punho (V vs U) zerava o modelo antes, e como o verificador biomecânico funciona sem ser "gambiarra"?

Resposta: No LibraSign, os vídeos são gravados por sinalizador contínuo; 194 das 210 distâncias par-a-par descrevem o punho fechado (anelar, mínimo, palma), e só 16 envolvem indicador e médio. A MLP aprendia o atalho do formato do punho daquela pessoa. Corrigimos primeiro no **treino** (transplante dos dedos ativos sobre punhos doadores + jitter nas falanges dobradas) e adicionamos um **pós-processamento biomecânico** apenas para pares mínimos ambíguos (U/V/R/N, M/W, G/L/Q), medindo razões de extensão e ângulo de abertura (por exemplo, V exige abertura ≥ 7,2° ou separação xy ≥ 0,24; R verifica cruzamento das pontas).

4. Por que a acurácia no MINDS-Libras parou em 51,89%? Isso não é baixo?

Resposta: Em um problema de **20 classes**, o acaso é 5%, então 51,89% representa mais de 10× o acaso e um salto de 3,31× sobre nosso baseline (15,68%) sob partição estrita inter-sinalizador — com apenas 3 pessoas (303 vídeos) no treino. O teto de ~52% expõe duas limitações reais e honestas que motivam nossos trabalhos futuros: (1) landmarks apenas das mãos não captam rosto/expressões não manuais nem posição relativa ao tronco/queixo (fundamentais em sinais do MINDS como *Banheiro* ou *Desculpa*); e (2) 3 sinalizadores no treino ainda são poucos para cobrir toda a variabilidade antropométrica humana.

5. Por que a GRU de saudações tem H=64 e a da MINDS tem H=128? E por que a confiança mínima é 0,40 e 0,35?

Resposta: No Módulo 2 do app são apenas 9 classes distintas entre si, então `H=64` já atinge 100% na base e custa só 1,4 ms no navegador; no MINDS (20 classes com sinais parecidos) usamos `H=128` por maior capacidade representacional. Já os limiares de 0,40 (A–Z) e 0,35 (saudações) existem porque o modelo é treinado com *label smoothing* (0,05) e o gesto humano em webcam real raramente replica 100% o pico estático do estúdio — a segurança contra falso positivo vem da combinação do limiar com a **sustentação contínua** na janela temporal.

6. Como o app lida com as letras dinâmicas do alfabeto (J, Z, H, K, X)?

Resposta: Na visualização pedagógica, o modelo 3D em Three.js anima explicitamente a trajetória dessas 5 letras para o aluno aprender o movimento. Na etapa de avaliação pela webcam, a MLP classifica hoje a configuração de mão canônica associada à letra. Integrar um verificador de trajetória específico para J, Z, H, K e X está listado exatamente como um dos nossos próximos passos.

7. O que acontece quando a mão sai da tela ou uma mão fica oculta nas saudações de duas mãos?

Resposta: No vetor de 128 posições por quadro (`63 esq + 1 máscara + 63 dir + 1 máscara`), o bit de máscara vai para 0 e as 63 coordenadas da mão ausente são zeradas. Durante o aumento de dados, multiplicamos o ruído e a translação pela máscara binária (`× m_t`) e reamostramos a máscara por vizinho mais próximo — garantindo que uma mão ausente nunca receba ruído gaussiano sintético que pareça uma "mão fantasma".

8. Se o MediaPipe leva 87,3% do tempo (27,5 ms), como otimizar ainda mais o sistema?

Resposta: Como o gargalo está na etapa de detecção de landmarks em CPU/WASM (e não nas nossas redes neurais), as duas otimizações diretas são: habilitar o delegado WebGPU no MediaPipe Tasks Vision nos navegadores compatíveis e aplicar *frame skipping* adaptativo no detector em dispositivos mais fracos (ex.: rodar MediaPipe a 15–20 FPS interpolando a barra de progresso).

9. Por que vocês mediram latência em um Apple M4 e não em um computador mais simples?

Resposta: O Apple M4 foi nossa bancada local de desenvolvimento rodando via WebAssembly em CPU (sem GPU dedicada para MLP/GRU). Reconhecemos isso como um limite do relato — em máquinas escolares mais modestas, a taxa de quadros pode cair abaixo de 30 FPS por conta do MediaPipe, embora o custo marginal das nossas redes (1,45 ms) continue desprezível. Testar o perfil de latência em hardware de baixo custo e fazer um estudo longitudinal em sala de aula faz parte dos próximos passos.

10. O DuoLibras traduz Libras contínua em frases?

Resposta: Não, e essa delimitação de escopo é intencional. Tradução contínua irrestrita exige segmentação automática de fronteiras entre sinais, expressões faciais gramaticais (Face Mesh) e tradução semântica glosa→português com LLMs. O DuoLibras foca no domínio pedagógico estruturado: ensino ativo de dactilologia e expressões isoladas de saudação com feedback biomecânico imediato.